

PRÁCTICA 1: WEB SCRAPING

Byron Lima Rojas
bvlima@uoc.edu

3 de noviembre de 2017

Índice

1. Título	3
2. Subtítulo	3
3. Imagen - Identificativo del Dataset	3
4. Contexto. ¿Cuál es la materia del conjunto de datos?	3
5. Contenido. ¿Qué campos incluye? ¿Cuál es el periodo de tiempo de los datos y cómo se ha recogido?	4
6. Agradecimientos. ¿Quién es el propietario del conjunto de datos?	4
7. Inspiración. ¿Por qué es interesante este conjunto de datos? ¿Qué preguntas le gustaría responder a la comunidad?	5
8. Licencia	6
9. Código fuente	6
10.Dataset	7
11.Bibliografía	8

1. Título

Alojamientos en Loja - Airbnb en conjunto con el Festival de Artes Vivas 2017

2. Subtítulo

Información de alquiler de habitaciones, casas y departamentos en la ciudad de Loja, Ecuador. Airbnb como otra alternativa para asistir al Festival de Artes Vivas a desarrollarse en el mes de Noviembre en la capital musical.

3. Imagen - Identificativo del Dataset



4. Contexto. ¿Cuál es la materia del conjunto de datos?

El conjunto de datos es analizado en su mayor parte por la estadística, en donde cada columna representa el valor de una variable y cada fila es considerado un registro o información de un elemento del conjunto, también conocido como dato. En la actualidad esta información puede ser extraída desde una base de datos o mediante técnicas de extracción de información, la misma tendrá que pasar un ciclo de vida hasta llegar a la publicación de datos y conclusiones de la misma (Wiki, 2017).

A la información obtenida de los diferentes sitios web, deben pasar por un proceso de eliminación de registros "basura" que no aportan a la toma de decisiones, una vez realizado este proceso es importante preparar los datos para su análisis evitando de esta forma realizar conclusiones y recomendaciones erróneas. Adicional es importante realizar las clasificaciones de datos cuantitativos de acuerdo a ciertos intervalos que nos permita realizar a la información un análisis semántico.

Los elementos que constituyen este conjunto de datos se basa en el tipo de alojamiento, número de baños, número de camas, y número de huéspedes. Mediante esta información nos permitirá realizar el analizar datos para realizar recomendaciones al usuario final.

Existen conjuntos de datos procedentes de hoteles para ser analizados desde la perspectiva de clasificación de opiniones, ubicaciones, impuestos, costos, entre otros. Esta información se encuentra en repositorios de universidades y ayuntamientos de ciudades para utilización de forma pública.

5. Contenido. ¿Qué campos incluye? ¿Cuál es el periodo de tiempo de los datos y cómo se ha recogido?

Mediante la librería scrapy de Python 2.7 se obtienen los siguientes datos de Airbnb:

- Baños
- Dormitorios
- Huéspedes
- Tipo

De la librería de scrapy, se utilizan las siguientes clases para obtener los datos:

- `from scrapy.item import Item, Field`: permite crear la clase tipo Ítem y definir la estructura de los datos que vamos a obtener de un sitio web.
- `from scrapy.spiders import CrawlSpider, Rule`: define las reglas que debe seguir el spider para revisar datos y se crea la clase que hereda `CrawlSpider` que nos permite ir de forma horizontal y vertical.
- `from scrapy.loader import ItemLoader`: establece el inicio de la recolección de datos por las diferentes etiquetas del sitio web, los datos se obtienen mediante código Xpath del navegador Chrome.
- `from scrapy.linkextractors import LinkExtractor`: define el recorrido que debe realizar el spider para obtener los datos, adicional define hacia qué página o subsitios puede acceder.
- `from scrapy.loader.processors import MapCompose`: permite editar los datos extraídos mediante funciones lambda.

El periodo de tiempo de los datos en la parte de recolección tardó un minuto, en la parte de vigencia de los mismos puede ser de 15 días por el incremento de lugares que puedan ofertarse.

6. Agradecimientos. ¿Quién es el propietario del conjunto de datos?

El propietario de estos datos es el administrador de Airbnb, que ha permitido la posibilidad de capturar datos desde su sitio web. A mi persona, por el afán invertido en conocer y dominar tecnologías aplicadas al tratamiento de datos, siempre con el propósito de generar conocimiento y convertir la información en valor agregado al usuario final.

7. Inspiración. ¿Por qué es interesante este conjunto de datos? ¿Qué preguntas le gustaría responder a la comunidad?

El conjunto de datos obtenido desde sitios web de alojamientos es importante entre grandes empresas, familias numerosas y viajeros, es una forma de encontrar sitios a buen precio cuando se trata de viajar a otra ciudad, de esta forma se optimizan gastos de estadía.

De acuerdo a los datos obtenidos, nos permitirá indicar al usuario el número de habitaciones que cuenta el lugar, número de baños, cantidad de camas y el máximo de personas admitidas por lugar, de esta forma el usuario/empresa determinará el sitio que se acople a sus necesidades.

En mi experiencia en viajes realizados a varias ciudades del Ecuador; ya sea por trabajo, estudios o turismo de forma personal o en grupo siempre he tenido inconvenientes en encontrar un lugar que se acople a mis necesidades a la primera, sea por temas de logística, comodidad, privacidad, baños compartidos, horarios de llegada e itinerios de ciertos establecimientos de brindan servicios de hospedaje. En Airbnb, es importante destacar que se pueden encontrar disponibilidad de habitaciones, departamentos y casas de todo tipo.

En el mes de noviembre del año en curso, en la ciudad de Loja se desarrollará por segundo año consecutivo el Festival de Artes Vivas, para lo cual se pronostica la llegada de alrededor de 100,000 personas por motivo de las diferentes presentaciones a realizarse en los 12 días de duración del evento, al momento existen hoteles con aforos llenos para lo cual es importante destacar el servicio de Airbnb como otra alternativa. Mediante la captura de datos, se busca ayudar a los turistas a elegir de acuerdo a los siguientes criterios:

- Para grupos familiares, destacar los lugares disponibles de acuerdo al número de habitaciones y camas que se acoplen a las necesidades del total de huéspedes en sitios de tipo casa o departamento.
- En el caso de grupos de trabajo, destacar departamentos cerca de los sitios de trabajo clasificando por número de habitaciones con baño propio, por temas de tiempo es indispensable contar con cuarto de aseo individual.
- Para personas que viajan de forma individual o pareja, destacar la ubicación de los lugares que ofrecen habitaciones de forma individual con baño privado, el número de camas en la habitación.
- En forma general, presentar estos datos de manera informativa al usuario con las debidas sugerencias hacia quien está enfocado cada tipo de lugar, evitando así contratiempo en la toma de decisiones.

De esta forma, el usuario final realizará su elección de hospedaje eligiendo el tipo de lugar que más se adapte a sus necesidades, evitando así pérdida de tiempo en la búsqueda y análisis de las diferentes ofertas hoteleras encontradas en las páginas web de servicios.

8. Licencia



Práctica 1: Web Scraping by Lima Byron is licensed Under a [Creative Commons Reconocimiento- NoComercial-CompartirIgual 4.0 internacional Licence](#).

Nota: Es importante que la información se comparta igual, puesto que es información extraída para ser analizada desde un sitio web con determinada fecha de consulta. Adicional, no puede lucrarse de la misma puesto que la información pertenece a Airbnb y solo estamos consumiendo dichos datos para análisis de esta práctica. Destino a Uso Público.

9. Código fuente

Para la obtención de datos con Scrapy de Python se utilizaron las librerías de Scrapy, Buittwith, Python-Whois y Urllib2.

El código fuente es el siguiente:

```
from scrapy.item import Item, Field
from scrapy.spiders import CrawlSpider, Rule
from scrapy.loader import ItemLoader
from scrapy.linkextractors import LinkExtractor
from scrapy.loader.processors import MapCompose
_autor_ = 'ByronLimaRojas'

class HospedajeItem(Item):
    camas = Field()
    banios = Field()
    dormitorios = Field()
    huespedes = Field()
    tipo = Field()

class Airbnb(CrawlSpider):
    name = "Hospedaje"
    start_urls = ['https://www.airbnb.com/s/Loja']
    allowed_domains = ['airbnb.com']

    rules = (
        Rule(LinkExtractor(allow=r'page=')),
        Rule(LinkExtractor(allow=r'/rooms'), callback='parse_items')
    )

    def parse_items(self, response):
        item = ItemLoader(HospedajeItem(), response)
        item.add_xpath('camas',
            '//*[@id="summary"]/div[2]/div[1]/div[2]/div[1]/div[2]/div/div[3]/div/div[2]/span/text()',
            MapCompose(lambda i: i[0]))
```

```

item.add_xpath('banios',
                '//*[@id="summary"]/div[2]/div[1]/div[2]/div[1]/div[2]/div/div[4]/div/div[2]/span/text()',
                MapCompose(lambda j: j[0])),
item.add_xpath('dormitorios',
                '//*[@id="summary"]/div[2]/div[1]/div[2]/div[1]/div[2]/div/div[2]/div/div[2]/span/text()',
                MapCompose(lambda k: k[0])),
item.add_xpath('huespedes',
                '//*[@id="summary"]/div[2]/div[1]/div[2]/div[1]/div[2]/div/div[1]/div/div[2]/span/text()',
                MapCompose(lambda l: l[0])),
item.add_xpath('tipo',
                '//*[@id="summary"]/div[2]/div[1]/div[2]/div[1]/div[1]/div/div/div[1]/div[2]/div/div/span/a[1]/text()')
yield item.load_item()

```

10. Dataset

Los datos se encuentran en la ruta del repositorio github.com/byrvin17/WebScrapingPY bajo el nombre de **bnb.csv**. Los datos fueron exportados por consola bajo el siguiente comando: `scrapy runspider airbnb.py -o bnb.csv -t csv --set CLOSESPIDER_ITEMCOUNT=30`, esto con la finalidad de obtener los 30 primeros registros y evitar el baneo desde AirBNB.



```

Administrator: C:\Windows\System32\cmd.exe
2017-10-28 15:31:33 [scrapy.core.engine] DEBUG: Crawled (200) <GET https://www.a
irbnb.com/rooms/7651986?location=Leja> (referer: https://www.airbnb.com/s/Leja)
2017-10-28 15:31:33 [scrapy.core.scraper] DEBUG: Scraped from (200 https://www.a
irbnb.com/rooms/4358665?location=Leja)
{'banios': ['1'],
 'camas': ['1'],
 'dormitorios': ['1'],
 'huespedes': ['2'],
 'tipo': ['Private room in house']}
2017-10-28 15:31:33 [scrapy.core.scraper] DEBUG: Scraped from (200 https://www.a
irbnb.com/rooms/7651986?location=Leja)
{'banios': ['1'],
 'camas': ['2'],
 'dormitorios': ['2'],
 'huespedes': ['4'],
 'tipo': ['Entire apartment']}
2017-10-28 15:31:35 [scrapy.core.engine] DEBUG: Crawled (200) <GET https://www.a
irbnb.com/rooms/3151782?location=Leja> (referer: https://www.airbnb.com/s/Leja)
2017-10-28 15:31:35 [scrapy.core.scraper] DEBUG: Scraped from (200 https://www.a
irbnb.com/rooms/3151782?location=Leja)
{'banios': ['1'],
 'camas': ['1'],
 'dormitorios': ['1'],
 'huespedes': ['2'],
 'tipo': ['Entire apartment']}
2017-10-28 15:31:38 [scrapy.core.engine] DEBUG: Crawled (200) <GET https://www.a
irbnb.com/rooms/2413982?location=Leja> (referer: https://www.airbnb.com/s/Leja)
2017-10-28 15:31:38 [scrapy.core.scraper] DEBUG: Scraped from (200 https://www.a
irbnb.com/rooms/2413982?location=Leja)
{'banios': ['1'],
 'camas': ['3'],
 'dormitorios': ['2'],
 'huespedes': ['4'],
 'tipo': ['Entire apartment']}
2017-10-28 15:31:38 [scrapy.core.engine] INFO: Closing spider (finished)
2017-10-28 15:31:38 [scrapy.extensions.feedexport] INFO: Stored csv feed (18 ite
ms) in: airbnbloja1.csv
2017-10-28 15:31:38 [scrapy.statscollectors] INFO: Dumping Scrapy stats:
{'downloader/request_bytes': 14755,
 'downloader/request_count': 20,
 'downloader/request_method_count/GET': 20,
 'downloader/response_bytes': 2858895,
 'downloader/response_count': 20,
 'downloader/response_status_count/200': 20,
 'finish_reason': 'finished',
 'finish_time': datetime.datetime(2017, 10, 28, 20, 31, 38, 847000),
 'item_scraped_count': 18,
 'log_count/DEBUG': 39,
 'log_count/INFO': 8,
 'request_depth_max': 1,
 'response_received_count': 20,
 'scheduler/dequeued': 19,
 'scheduler/dequeued/memory': 19,
 'scheduler/enqueued': 19,
 'scheduler/enqueued/memory': 19,
 'start_time': datetime.datetime(2017, 10, 28, 20, 31, 21, 543000)}
2017-10-28 15:31:38 [scrapy.core.engine] INFO: Spider closed (finished)

```

Figura 1: Ejecución de Scrapy en consola

11. Bibliografía

Referencias

- [1] Conjunto de Datos (2017) [En línea]. Wiki - UMAIC [Consulta: 28/10/2017]. https://wiki.umaic.org/wiki/Conjunto_de_datos.
- [2] Hotel/Motel Tax Collected by Jurisdiction and Quarter (2017). [En línea]. Data.GOV [Consulta: 03/11/2017]. <https://catalog.data.gov/dataset/hotel-motel-tax-collected-by-jurisdiction-and-quarter>
- [3] Localización de hoteles Loja (2017). [En línea]. Ambar - Linked Open Data Portal [Consulta: 03/11/2017]. <http://ambar.utpl.edu.ec/sv/dataset/localizacion-de-hoteles-loja>
- [4] Lozano, Esteban V. (2017). Preprocesamiento de los datos. Universitat Oberta de Catalunya fondo editorial.
- [5] Moreno-Ibarra, Marco, et al (2011). "Semantic assessment of similarity between raster elevation datasets/Valoración Semántica De La Similitud Entre Conjuntos De Datos Raster De Elevación". Revista Facultad de Ingeniería Universidad de Antioquia (59, página 37).